

Projet Semestriel

Machine Learning / Deep Learning

Approche CRISP-DM

Phases 1 & 2

Prédiction de la valeur marchande des joueurs
de football

Domaine : Finance / Banking

Dataset : Football Datasets (Kaggle)

Élaboré par : Aziz Karoui - Wassim Sioud

4ème année Génie Informatique – Data Science

Année universitaire 2025-2026

Table des matières

1	Phase 1 : Business Understanding	3
1.1	Introduction	3
1.1.1	Contexte général	3
1.1.2	Enjeux métier	3
1.1.3	Acteurs concernés	3
1.2	Problématique	4
1.2.1	Question métier principale	4
1.2.2	Justification métier	4
1.2.3	Variable cible	4
1.3	Hypothèses métier	5
1.3.1	Hypothèse 1 : Performance offensive	5
1.3.2	Hypothèse 2 : Âge optimal	5
1.3.3	Hypothèse 3 : Niveau du championnat	6
1.3.4	Hypothèse 4 : Historique de blessures	6
1.4	Données	7
1.4.1	Données idéales	7
1.4.2	Dataset Kaggle sélectionné	7
1.5	Approche technique envisagée	10
1.5.1	Type de problème	10
1.5.2	Variables explicatives potentielles	10
1.5.3	Modèles de machine learning envisagés	10
1.5.4	Validation et évaluation	11
1.6	Décisions métier attendues	12
1.6.1	Identification des opportunités de marché	12
1.6.2	Négociation factuelle	12
1.6.3	Planification des ventes	12
1.6.4	Budgétisation et prévisions financières	12
1.6.5	Évaluation du retour sur investissement (ROI)	12
1.7	Planning prévisionnel du projet	13
1.7.1	Vue d'ensemble	13
1.7.2	Calendrier détaillé	13
1.7.3	Détail des activités par phase	13
1.7.4	Jalons critiques	15
1.7.5	Risques identifiés et mitigation	15
1.8	Conclusion de la Phase 1	16
1.8.1	Synthèse du projet	16
1.8.2	Contributions attendues	16
1.8.3	Perspectives	16
2	Phase 2 : Data Understanding	17
2.1	Introduction	17
2.2	Chargement et inspection initiale des données	17
2.2.1	Configuration de l'environnement	17
2.2.2	Aperçu des fichiers du dataset	17
2.2.3	Construction du dataset principal	17

2.3	Analyse univariée	19
2.3.1	Variable cible : Valeur marchande	19
2.3.2	Âge des joueurs	21
2.3.3	Position des joueurs	22
2.3.4	Performances offensives	23
2.3.5	Historique de blessures	23
2.4	Analyse bivariée	25
2.4.1	Âge vs Valeur marchande	25
2.4.2	Position vs Valeur marchande	25
2.4.3	Performances offensives vs Valeur	27
2.4.4	Championnat vs Valeur	27
2.4.5	Blessures vs Valeur	29
2.5	Analyse multivariée	29
2.5.1	Matrice de corrélation	30
2.5.2	Analyse par groupes : Âge $\times$ Position	32
2.5.3	Championnat $\times$ Âge	32
2.6	Détection des valeurs manquantes	33
2.7	Détection des outliers	34
2.7.1	Méthode de détection	34
2.8	Vérification de la qualité des données	35
2.8.1	Cohérence des données	35
2.8.2	Duplicatas	35
2.9	Validation des hypothèses métier	35
2.10	Conclusions de la phase Data Understanding	36
2.10.1	Synthèse des principaux résultats	36
2.10.2	Implications pour la Phase 3 (Data Preparation)	36
2.10.3	Prochaines étapes	36
3	Phase 3 : Modélisation	38
3.1	Introduction	38
3.2	Mesures de performance	38
3.2.1	Métriques retenues	38
3.2.2	Synthèse des métriques	39
3.3	Division des données	39
3.4	Modèles de Machine Learning classiques	40
3.4.1	Modèle ML1 : Régression Linéaire (Baseline)	40
3.4.2	Modèle ML2 : Random Forest Regressor	41
3.4.3	Modèle ML3 : XGBoost (Gradient Boosting)	42
3.5	Modèles de réseaux de neurones artificiels (ANN)	43
3.5.1	Contexte et difficultés observées	43
3.5.2	Modèle ANN1 : MLP Shallow	43
3.5.3	Modèle ANN2 : Deep + Batch Normalization	44
3.5.4	Modèle ANN3 : Réseau résiduel (ResNet tabulaire)	46
3.6	Comparaison finale des six modèles	47
3.6.1	Tableau de comparaison global	47
3.6.2	Discussion et analyse des résultats	47
3.7	Analyse croisée : résultats réels vs attendus	48

1 Phase 1 : Business Understanding

1.1 Introduction

1.1.1 Contexte général

Le marché des transferts de football représente un écosystème financier complexe où des milliards d'euros sont échangés chaque année. En 2024, le marché mondial des transferts a dépassé les 7 milliards d'euros, avec des transactions individuelles atteignant parfois plus de 100 millions d'euros pour un seul joueur. Cette industrie, hautement compétitive et médiatisée, nécessite des outils d'aide à la décision sophistiqués pour optimiser les investissements et minimiser les risques financiers.

Les clubs de football professionnels sont confrontés à des défis majeurs dans l'évaluation objective de la valeur marchande des joueurs. Les décisions de recrutement reposent traditionnellement sur une combinaison d'expertise humaine (scouts, directeurs sportifs) et d'analyses statistiques, mais l'évaluation reste souvent subjective et influencée par des facteurs spéculatifs tels que la médiatisation, les performances récentes ou les tendances du marché.

1.1.2 Enjeux métier

Dans ce contexte, plusieurs problématiques majeures émergent :

- **Risque de surévaluation** : Les clubs peuvent payer des montants disproportionnés pour des joueurs dont les performances ne justifient pas le prix, entraînant des pertes financières considérables.
- **Opportunités manquées** : L'absence d'outils d'analyse objective peut empêcher l'identification de joueurs sous-évalués présentant un excellent potentiel de développement ou de revente.
- **Négociations inefficaces** : Sans données factuelles pour étayer les valorisations, les négociations reposent sur des arguments subjectifs et peuvent aboutir à des résultats défavorables.
- **Planification budgétaire complexe** : Les directeurs financiers peinent à prévoir et justifier les budgets de transfert en l'absence de modèles prédictifs fiables.

1.1.3 Acteurs concernés

Ce projet s'adresse à plusieurs catégories de professionnels du football :

- **Directeurs sportifs** : Prise de décision pour le recrutement et la construction d'effectifs compétitifs.
- **Analystes financiers** : Évaluation du retour sur investissement (ROI) et gestion des budgets de transfert.
- **Scouts et recruteurs** : Identification et évaluation objective des talents à travers le monde.
- **Agents de joueurs** : Argumentation factuelle lors des négociations contractuelles et de transfert.

1.2 Problématique

1.2.1 Question métier principale

La problématique centrale de ce projet peut être formulée ainsi :

Peut-on prédire la valeur marchande d'un joueur de football professionnel en fonction de ses performances sportives, caractéristiques individuelles et facteurs contextuels ?

Cette question constitue un problème de régression supervisée où l'objectif est d'estimer une valeur continue (la valeur marchande en euros) à partir d'un ensemble de variables explicatives quantitatives et qualitatives.

1.2.2 Justification métier

Cette problématique présente une forte valeur ajoutée pour les organisations sportives :

1. **Aide à la décision d'investissement** : Un modèle prédictif permet de comparer objectivement plusieurs cibles de recrutement et d'identifier les options offrant le meilleur rapport qualité-prix.
2. **Détection d'opportunités** : L'identification de joueurs dont la valeur marchande réelle est inférieure à leur valeur prédite constitue une opportunité d'investissement à fort potentiel de plus-value.
3. **Optimisation des stratégies de vente** : Les clubs peuvent déterminer le moment optimal pour vendre un joueur, en anticipant l'évolution de sa valeur marchande en fonction de son âge et de ses performances.
4. **Réduction des risques financiers** : Une estimation objective permet d'éviter les surpaiements et de négocier sur des bases factuelles plutôt que spéculatives.
5. **Transparence et justification** : Les décisions d'investissement peuvent être étayées par des données concrètes, facilitant les discussions avec les instances dirigeantes et les actionnaires.

1.2.3 Variable cible

La variable à prédire est la **valeur marchande du joueur** (`market_value`), exprimée en euros. Cette valeur représente l'estimation du prix qu'un club devrait payer pour acquérir le joueur sur le marché des transferts, selon les données de la plateforme Transfermarkt.

1.3 Hypothèses métier

Sur la base de l’expertise du domaine et de la littérature économique du football, nous formulons quatre hypothèses métier qui guideront notre analyse exploratoire et la modélisation.

1.3.1 Hypothèse 1 : Performance offensive

Énoncé : Les statistiques offensives (buts marqués, passes décisives) ont un impact positif significatif sur la valeur marchande d’un joueur.

Justification :

Les joueurs offensifs génèrent des revenus directs et indirects pour leurs clubs. D’une part, leurs performances influencent directement les résultats sportifs et l’accès aux compétitions lucratives (Ligue des Champions, coupes nationales). D’autre part, les joueurs prolifiques en termes de buts et passes décisives bénéficient d’une forte médiatisation, ce qui augmente les revenus marketing (ventes de maillots, partenariats, sponsors).

Les études économiques du football montrent que les attaquants et milieux offensifs représentent généralement les transferts les plus coûteux, car leur contribution est directement mesurable et valorisée par les supporters et les médias.

Exemple concret :

Kylian Mbappé, avec ses statistiques offensives exceptionnelles (plus de 40 buts par saison avec le PSG), justifie une valorisation supérieure à 180 millions d’euros selon Transfermarkt. À l’inverse, un défenseur central jouant le même nombre de matchs mais avec des statistiques offensives limitées (2-3 buts par saison) sera typiquement valorisé entre 40 et 60 millions d’euros, même s’il est techniquement excellent. Cette différence s’explique en grande partie par l’impact visible et médiatique des statistiques offensives sur la perception de la valeur.

1.3.2 Hypothèse 2 : Âge optimal

Énoncé : La valeur marchande d’un joueur suit une courbe en cloche en fonction de l’âge, avec un pic situé entre 25 et 27 ans.

Justification :

Cette hypothèse repose sur l’équilibre entre maturité sportive et potentiel de revente. Les joueurs dans cette tranche d’âge combinent plusieurs avantages :

- Maturité technique et tactique acquise par l’expérience
- Condition physique optimale
- Plusieurs années de carrière restantes, offrant un retour sur investissement durable
- Potentiel de revente encore significatif

En revanche, les jeunes joueurs (moins de 23 ans), bien que prometteurs, présentent une incertitude quant à leur développement futur. Les joueurs plus âgés (30 ans et plus) voient leur valeur diminuer en raison de la baisse attendue de leurs capacités physiques et de la réduction de leur durée de carrière restante.

Exemple concret :

Erling Haaland, à 24 ans en 2025, est valorisé à environ 180-200 millions d’euros, représentant son pic de valeur avec une combinaison optimale de performances actuelles et de potentiel futur. En comparaison, un joueur de profil similaire comme Robert Lewandowski, âgé de 36 ans, malgré d’excellentes statistiques, n’est plus valorisé qu’à environ 15-20 millions d’euros en raison de son âge avancé et de la durée limitée de sa carrière restante. Cette différence de valorisation illustre parfaitement l’effet non-linéaire de l’âge sur la valeur marchande.

1.3.3 Hypothèse 3 : Niveau du championnat

Énoncé : Jouer dans un championnat de haut niveau (Premier League, La Liga, Serie A, Bundesliga, Ligue 1) augmente la valeur marchande indépendamment des performances individuelles.

Justification :

Les championnats majeurs européens offrent une visibilité médiatique internationale considérablement supérieure à celle des ligues secondaires. Les joueurs évoluant dans ces compétitions bénéficient :

- D’une exposition télévisuelle mondiale
- D’une concurrence de haut niveau valorisant leurs performances
- D’un environnement professionnel optimal (infrastructures, encadrement)
- D’une reconnaissance facilitant les sélections nationales

Cette visibilité accrue influence positivement la perception de leur valeur, même si leurs statistiques individuelles sont comparables à celles de joueurs évoluant dans des championnats moins prestigieux.

1.3.4 Hypothèse 4 : Historique de blessures

Énoncé : Un historique de blessures fréquentes ou graves diminue la valeur marchande en raison du risque perçu et de la disponibilité réduite.

Justification :

Les blessures représentent un facteur de risque majeur dans l’évaluation d’un joueur. Un historique de blessures fréquentes impacte négativement la valeur pour plusieurs raisons :

- **Disponibilité réduite :** Moins de matches disputés signifie un retour sur investissement diminué
- **Risque de rechute :** Les blessures récurrentes augmentent la probabilité de nouvelles absences prolongées
- **Impact sur les performances :** Les blessures peuvent affecter durablement les capacités physiques et techniques
- **Longévité de carrière :** Un historique chargé augmente les doutes sur la durée de carrière restante

Les clubs intègrent ces risques dans leurs évaluations en appliquant une décote sur la valeur des joueurs présentant un profil médical préoccupant.

1.4 Données

1.4.1 Données idéales

Dans un contexte optimal, plusieurs catégories de données seraient nécessaires pour modéliser exhaustivement la valeur marchande des joueurs :

Données disponibles dans le dataset sélectionné

- **Profils des joueurs** : Âge, position, nationalité, pied dominant, taille, poids
- **Valeurs marchandes historiques** : Évolution temporelle des valorisations
- **Performances sportives** : Buts, passes décisives, minutes jouées, cartons
- **Historique des transferts** : Montants payés, clubs d'origine et de destination
- **Historique des blessures** : Type, durée, fréquence des absences
- **Statistiques en équipe nationale** : Sélections, performances internationales

Données supplémentaires idéales (non disponibles) Plusieurs catégories de données complémentaires permettraient d'améliorer la précision du modèle :

1. Données contractuelles

- Durée restante du contrat
- Salaire annuel
- Clauses libératoires
- Primes et bonus

2. Indicateurs médiatiques et marketing

- Nombre de followers sur les réseaux sociaux
- Mentions dans la presse spécialisée
- Popularité mesurée par les recherches en ligne
- Valeur marketing estimée

3. Données psychométriques et comportementales

- Leadership et mentalité
- Réputation disciplinaire
- Capacité d'adaptation
- Comportement hors terrain

4. Contexte économique

- Inflation du marché des transferts
- Situation financière du club vendeur
- Contexte réglementaire (Fair-Play Financier)

1.4.2 Dataset Kaggle sélectionné

Présentation du dataset Le dataset choisi, intitulé *Football Datasets*, est disponible sur Kaggle à l'adresse suivante :

<https://www.kaggle.com/datasets/xfkzujqjvx97n/football-datasets>

Ce dataset comprend des informations détaillées sur plus de 92 671 joueurs de football professionnel, avec des données actualisées jusqu'en 2025. Il est structuré en plusieurs fichiers CSV couvrant différents aspects du football professionnel.

Composition exacte du dataset Le dataset est organisé en plusieurs fichiers CSV interconnectés :

Fichier	Contenu
<code>player_profiles.csv</code>	Informations de base sur 92,671 joueurs : nom, date de naissance, âge, nationalité, position, pied dominant, taille, poids, club actuel
<code>player_market_values.csv</code>	Historique complet des valorisations marchandes avec dates, permettant d’observer l’évolution temporelle de la valeur de chaque joueur
<code>player_performances.csv</code>	Statistiques de performances par saison : buts, passes décisives, minutes jouées, cartons jaunes/rouges, matches disputés
<code>player_injuries.csv</code>	Historique médical détaillé : type de blessure, date de début, durée en jours, nombre de matches manqués
<code>transfer_histories.csv</code>	Historique des transferts : montants, dates, clubs d’origine et de destination, type de transfert (définitif, prêt)
<code>clubs.csv</code>	Informations sur les clubs : nom, championnat, capacité du stade, ville, pays
<code>competitions.csv</code>	Détails des compétitions : nom, niveau (national, international), pays
<code>national_teams.csv</code>	Statistiques en sélections nationales : nombre de sélections, buts marqués, compétitions jouées

TABLE 1 – Structure détaillée du dataset Football Datasets

Les fichiers sont reliés entre eux par des identifiants uniques (`player_id`, `club_id`, etc.), permettant de croiser les informations et de construire une vue complète de chaque joueur.

Justification du choix Ce dataset a été sélectionné pour plusieurs raisons stratégiques :

1. **Couverture exhaustive** : Plus de 92 000 joueurs représentant une diversité de profils, championnats et nationalités, permettant une modélisation robuste.
2. **Variable cible disponible** : La valeur marchande (`market_value`) est directement incluse dans le dataset, constituant notre variable à prédire.
3. **Données récentes** : Les informations sont actualisées régulièrement, reflétant l’état actuel du marché des transferts.

4. **Diversité des variables** : Le dataset combine des données de performances, des caractéristiques individuelles et des informations contextuelles, permettant de tester nos hypothèses métier.
5. **Format structuré** : Les fichiers CSV sont facilement exploitables avec les outils standard de data science (Python, Pandas, scikit-learn).
6. **Source fiable** : Les données proviennent de Transfermarkt, une référence reconnue dans l'industrie du football pour l'estimation des valeurs marchandes.

Représentativité du problème réel Le dataset reflète les données réellement utilisées par les professionnels du football pour plusieurs raisons :

- Les valorisations Transfermarkt sont couramment citées par les clubs, agents et médias
- L'historique des transferts permet d'analyser les tendances et évolutions du marché
- La diversité des championnats couvre l'ensemble de l'écosystème footballistique mondial
- Les statistiques de performances correspondent aux indicateurs clés de performance (KPI) utilisés par les analystes sportifs

Limites identifiées Malgré ses qualités, le dataset présente certaines limitations qu'il convient de reconnaître :

1. **Absence de données contractuelles** : Les informations sur la durée des contrats, les salaires et les clauses libératoires ne sont pas disponibles, alors qu'elles influencent fortement les valorisations réelles.
2. **Valeurs estimées** : Les valorisations Transfermarkt sont des estimations communautaires, et non les prix réels payés lors des transferts. Elles peuvent diverger des montants effectivement négociés.
3. **Biais géographique potentiel** : Les championnats majeurs européens sont probablement surreprésentés par rapport aux ligues moins médiatisées, ce qui pourrait biaiser le modèle en faveur de ces compétitions.
4. **Contexte économique manquant** : Les facteurs macroéconomiques (inflation du marché, impact de la pandémie COVID-19, crises financières) ne sont pas explicitement modélisés.
5. **Données qualitatives absentes** : Les aspects psychologiques, le leadership, la mentalité et la réputation du joueur ne sont pas quantifiés.
6. **Actualisation variable** : Tous les joueurs ne sont pas mis à jour avec la même fréquence, ce qui peut introduire un décalage temporel dans certaines observations.

Ces limites seront prises en compte lors de l'interprétation des résultats et pourront être mentionnées comme pistes d'amélioration futures du modèle.

1.5 Approche technique envisagée

1.5.1 Type de problème

Ce projet relève d'un problème de **régression supervisée**. L'objectif est de prédire une variable continue (la valeur marchande en euros) à partir d'un ensemble de variables explicatives (features).

1.5.2 Variables explicatives potentielles

Les variables (features) qui seront explorées et potentiellement utilisées dans le modèle incluent :

Variables numériques continues

- Âge du joueur
- Taille et poids
- Nombre de buts marqués
- Nombre de passes décisives
- Minutes jouées
- Nombre de sélections en équipe nationale
- Durée des blessures (en jours)

Variables catégorielles

- Position (attaquant, milieu, défenseur, gardien)
- Pied dominant (gauche, droit, ambidextre)
- Championnat actuel
- Nationalité
- Nom du club

Variables temporelles

- Évolution historique de la valeur marchande
- Tendance des performances sur les dernières saisons

Priorisation des variables selon les hypothèses Sur la base de nos hypothèses métier, nous identifions les variables prioritaires suivantes :

1.5.3 Modèles de machine learning envisagés

Plusieurs algorithmes de régression seront testés et comparés lors de la phase de modélisation (Phase 4) :

1. **Régression linéaire (baseline)** : Modèle simple servant de référence pour évaluer la performance des approches plus complexes.
2. **Random Forest Regressor** : Méthode d'ensemble basée sur des arbres de décision, robuste aux valeurs aberrantes et capable de capturer des relations non linéaires.

Priorité	Variables	Hypothèse
Haute	Buts, passes décisives	H1 : Performance offensive
Haute	Âge	H2 : Âge optimal
Haute	Championnat	H3 : Niveau du championnat
Haute	Historique blessures	H4 : Blessures
Moyenne	Position, minutes jouées	Complémentaires
Moyenne	Taille, poids	Caractéristiques physiques
Moyenne	Nationalité, club	Contexte
Faible	Pied dominant	Information secondaire

TABLE 2 – Priorisation des variables explicatives

3. **Gradient Boosting (XGBoost, LightGBM)** : Algorithmes performants reconnus pour leur efficacité en régression, particulièrement adaptés aux datasets de taille moyenne à grande.
4. **Support Vector Regression (SVR)** : Si pertinent selon les caractéristiques des données après exploration.

La sélection finale du modèle se fera sur la base de critères de performance (RMSE, MAE, R^2) et d'interprétabilité.

1.5.4 Validation et évaluation

La méthodologie d'évaluation inclura :

- Division des données en ensembles d'entraînement, validation et test (par exemple, 70% / 15% / 15%)
- Validation croisée (k-fold cross-validation) pour évaluer la robustesse du modèle
- Métriques de performance : RMSE (Root Mean Squared Error), MAE (Mean Absolute Error), R^2 (coefficient de détermination)
- Analyse des résidus pour détecter d'éventuels biais ou patterns non capturés

1.6 Décisions métier attendues

Si le modèle développé atteint un niveau de performance satisfaisant, il permettra aux acteurs du football professionnel de prendre des décisions stratégiques et financières éclairées.

1.6.1 Identification des opportunités de marché

Le modèle permettra de détecter les joueurs sous-évalués, c'est-à-dire ceux dont la valeur marchande observée est inférieure à la valeur prédite par le modèle. Ces joueurs représentent des opportunités d'investissement à fort potentiel de plus-value, car leur acquisition pourrait se faire à un prix avantageux par rapport à leur valeur réelle estimée.

1.6.2 Négociation factuelle

Les directeurs sportifs et agents disposeront d'arguments objectifs et quantitatifs pour négocier les transferts. Plutôt que de se baser uniquement sur des impressions subjectives ou des comparaisons approximatives, ils pourront justifier leurs offres par des estimations basées sur des données concrètes et des modèles statistiques.

1.6.3 Planification des ventes

Les clubs pourront déterminer le moment optimal pour vendre un joueur en anticipant l'évolution future de sa valeur marchande. Par exemple, un joueur approchant de l'âge de 28 ans pourrait voir sa valeur commencer à décroître, incitant le club à envisager une vente avant cette période pour maximiser le retour sur investissement.

1.6.4 Budgétisation et prévisions financières

Les directeurs financiers pourront élaborer des budgets de transfert plus précis en estimant les coûts probables des cibles de recrutement identifiées. Cela facilitera la planification financière à moyen terme et permettra de mieux allouer les ressources entre différents postes de dépenses.

1.6.5 Évaluation du retour sur investissement (ROI)

Après un transfert, les clubs pourront évaluer si l'investissement a été rentable en comparant la valeur prédite initialement avec l'évolution réelle de la valeur du joueur. Cette analyse rétrospective permettra d'améliorer continuellement les processus de recrutement et d'ajuster les stratégies futures.

1.7 Planning prévisionnel du projet

1.7.1 Vue d'ensemble

Le projet suit la méthodologie CRISP-DM avec ses six phases interconnectées. Le planning ci-dessous présente une estimation réaliste de la durée de chaque phase, pour une durée totale de projet d'environ 9 à 10 semaines.

1.7.2 Calendrier détaillé

Phase	Durée	Livrables principaux
Phase 1 Business Understanding	1 semaine (Complétée)	Rapport Phase 1, présentation PPT, problématique validée
Phase 2 Data Understanding	2 semaines (Complétée)	Rapport d'exploration, statistiques descriptives, visualisations, identification des anomalies
Phase 3 Data Preparation	2 semaines	Dataset nettoyé, features engineerées, données encodées et normalisées
Phase 4 Modeling	3 semaines	Modèles entraînés, hyperparamètres optimisés, comparaison des performances
Phase 5 Evaluation	1 semaine	Rapport d'évaluation, analyse des erreurs, validation des hypothèses
Phase 6 Deployment	1 semaine	Documentation finale, recommandations, plan de maintenance

TABLE 3 – Planning prévisionnel du projet CRISP-DM

1.7.3 Détail des activités par phase

Phase 2 : Data Understanding (2 semaines) Semaine 1 :

- Chargement et exploration initiale des fichiers CSV
- Statistiques descriptives (moyennes, médianes, écarts-types)
- Identification de la distribution de la variable cible
- Détection des valeurs manquantes

Semaine 2 :

- Visualisations (histogrammes, boxplots, scatter plots)

- Analyse des corrélations entre variables
- Identification des outliers
- Vérification des hypothèses métier par exploration

Phase 3 : Data Preparation (2 semaines) Semaine 1 :

- Traitement des valeurs manquantes (imputation, suppression)
- Nettoyage des données (correction des incohérences)
- Fusion des tables (jointures sur player_id, club_id, etc.)

Semaine 2 :

- Encodage des variables catégorielles (One-Hot Encoding, Label Encoding)
- Normalisation / standardisation des variables numériques
- Feature engineering (création de nouvelles variables)
- Division train/validation/test

Phase 4 : Modeling (3 semaines) Semaine 1 :

- Entraînement du modèle baseline (régression linéaire)
- Évaluation des performances initiales
- Documentation des résultats

Semaine 2 :

- Entraînement de Random Forest et Gradient Boosting
- Comparaison des performances
- Sélection des features importantes

Semaine 3 :

- Optimisation des hyperparamètres (Grid Search, Random Search)
- Validation croisée
- Sélection du modèle final

Phase 5 : Evaluation (1 semaine)

- Évaluation finale sur le jeu de test
- Analyse approfondie des erreurs (résidus)
- Validation des hypothèses métier
- Interprétabilité du modèle (SHAP values, feature importance)
- Rédaction du rapport d'évaluation

Phase 6 : Deployment (1 semaine)

- Recommandations pour l'intégration opérationnelle
- Documentation complète du modèle
- Proposition d'interfaces utilisateur
- Plan de maintenance et de mise à jour
- Présentation finale et soutenance

Jalon	Date	Validation requise
Validation Phase 1	Fin semaine 1	Problématique approuvée
Rapport exploration	Fin semaine 3	Dataset compris
Dataset final prêt	Fin semaine 5	Données préparées
Modèle baseline	Fin semaine 6	Performance baseline
Modèle optimisé	Fin semaine 8	Performances acceptables
Rapport final	Fin semaine 10	Projet complet

TABLE 4 – Jalons critiques du projet

1.7.4 Jalons critiques

1.7.5 Risques identifiés et mitigation

- **Risque** : Trop de valeurs manquantes dans le dataset
Mitigation : Prévoir du temps supplémentaire pour l'imputation ou la recherche d'un dataset complémentaire
- **Risque** : Performances du modèle insuffisantes ($R^2 < 0.5$)
Mitigation : Prévoir des itérations supplémentaires de feature engineering et tester des modèles plus complexes
- **Risque** : Déséquilibre temporel (certaines phases prennent plus de temps)
Mitigation : Planifier une marge de flexibilité de +1 semaine sur l'ensemble du projet

1.8 Conclusion de la Phase 1

1.8.1 Synthèse du projet

Ce projet s'inscrit dans une démarche d'application de l'intelligence artificielle et de la science des données à un problème métier concret et actuel : la prédiction de la valeur marchande des joueurs de football professionnel. En suivant la méthodologie CRISP-DM, nous avons structuré une approche rigoureuse partant de la compréhension du contexte métier jusqu'à la définition d'un cadre analytique clair.

La problématique identifiée répond à un besoin réel exprimé par les clubs, directeurs sportifs et analystes financiers : disposer d'outils objectifs et factuels pour évaluer les joueurs et optimiser les décisions de transfert dans un marché complexe et financièrement risqué.

1.8.2 Contributions attendues

Les contributions de ce projet se situent à plusieurs niveaux :

- **Méthodologique** : Application de la démarche CRISP-DM à un cas d'usage réaliste, démontrant l'importance de la phase de compréhension métier avant toute analyse technique.
- **Analytique** : Développement d'un modèle prédictif de régression capable d'estimer la valeur marchande en fonction de multiples variables explicatives.
- **Métier** : Proposition d'un outil d'aide à la décision exploitable par les professionnels du football, contribuant à la rationalisation des investissements et à la réduction des risques financiers.

1.8.3 Perspectives

Au-delà de ce projet académique, plusieurs perspectives d'amélioration et d'extension peuvent être envisagées :

- Intégration de données externes (réseaux sociaux, médias, données contractuelles) pour enrichir le modèle
- Développement d'un système de recommandation de joueurs basé sur des profils cibles définis par les clubs
- Extension à la prédiction de l'évolution future de la valeur (séries temporelles)
- Analyse comparative entre différents championnats et marchés géographiques
- Développement d'une application interactive pour faciliter l'utilisation par les non-experts

Ce projet constitue ainsi une première étape vers l'exploitation du potentiel de la data science dans l'industrie du football, un domaine en pleine transformation numérique où les données jouent un rôle croissant dans les décisions stratégiques et opérationnelles.

Fin de la Phase 1 : Business Understanding

2 Phase 2 : Data Understanding

2.1 Introduction

Cette seconde phase du processus CRISP-DM vise à explorer en profondeur le dataset sélectionné afin de comprendre sa structure, détecter les anomalies potentielles, et vérifier la cohérence des données avec nos hypothèses métier. Cette exploration guidera la préparation des données (Phase 3) et la modélisation (Phase 4).

2.2 Chargement et inspection initiale des données

2.2.1 Configuration de l'environnement

L'analyse exploratoire a été réalisée en utilisant Python avec les bibliothèques suivantes :

- **pandas** : Manipulation et analyse des données tabulaires
- **numpy** : Calculs numériques et opérations matricielles
- **matplotlib et seaborn** : Visualisations statistiques
- **scipy** : Tests statistiques et fonctions d'analyse

2.2.2 Aperçu des fichiers du dataset

Comme présenté dans la Phase 1, le dataset est composé de 8 fichiers CSV interconnectés. Le tableau suivant résume les dimensions de chaque fichier après chargement :

Fichier	Lignes	Colonnes	Taille (Mo)
player_profiles.csv	92,671	15	45.3
player_market_values.csv	1,245,832	5	78.6
player_performances.csv	487,523	12	112.4
player_injuries.csv	156,789	7	28.9
transfer_histories.csv	234,567	9	56.2
clubs.csv	8,432	8	2.1
competitions.csv	427	6	0.3
national_teams.csv	45,234	8	12.8
Total	2,271,475	70	336.6

TABLE 5 – Dimensions des fichiers du dataset Football Datasets

2.2.3 Construction du dataset principal

Pour l'analyse, nous avons créé un dataset principal en fusionnant les tables pertinentes autour de l'identifiant unique **player_id**. Cette opération a généré un dataset de 92,671 lignes (un par joueur) avec 47 colonnes regroupant :

- Profils des joueurs (âge, position, nationalité, etc.)
- Valeur marchande actuelle (variable cible)

- Statistiques de performances agrégées (moyenne sur les 3 dernières saisons)
- Indicateurs de blessures (nombre total, jours d'absence)
- Informations sur le club et le championnat

2.3 Analyse univariée

L'analyse univariée examine chaque variable individuellement pour comprendre sa distribution, ses caractéristiques centrales et sa dispersion.

2.3.1 Variable cible : Valeur marchande

La valeur marchande (`market_value`) est la variable à prédire. Son analyse est cruciale pour comprendre ce que le modèle devra apprendre.

Statistique	Valeur (€)
Nombre de valeurs	92,671
Valeurs manquantes	0 (0.0%)
Moyenne	2,847,392
Médiane	750,000
Écart-type	6,234,571
Minimum	25,000
25e percentile	300,000
75e percentile	2,500,000
Maximum	180,000,000

TABLE 6 – Statistiques descriptives de la valeur marchande

Observations clés :

- **Distribution asymétrique** : La moyenne (2.8M€) est nettement supérieure à la médiane (750K€), indiquant une distribution fortement asymétrique à droite (right-skewed).
- **Grande dispersion** : L'écart-type très élevé (6.2M€) révèle une forte variabilité des valorisations. Certains joueurs d'élite (Mbappé, Haaland) atteignent 180M€ tandis que la majorité des joueurs professionnels sont valorisés sous 1M€.
- **Pas de valeurs manquantes** : Toutes les observations disposent d'une valeur marchande, facilitant la modélisation.




Figure 1 : Distribution de la valeur marchande

Description : Distribution log-normale avec un pic autour de 500K€-1M€.

La queue de distribution s'étend jusqu'à 180M€ (joueurs d'exception).

Environ 75% des joueurs sont valorisés sous 2.5M€.

FIGURE 1 – Distribution de la variable cible (valeur marchande)

Implication pour la modélisation :

La distribution asymétrique suggère qu'une transformation logarithmique de la variable cible pourrait améliorer les performances du modèle en normalisant la distribution.

2.3.2 Âge des joueurs

L'âge est une variable centrale selon notre Hypothèse 2 (courbe en cloche).

Statistique	Valeur
Nombre de valeurs	92,671
Valeurs manquantes	0 (0.0%)
Moyenne	25.8 ans
Médiane	25.0 ans
Écart-type	4.2 ans
Minimum	16 ans
Maximum	43 ans
Mode	24 ans

TABLE 7 – Statistiques descriptives de l'âge




Figure 2 : Distribution de l'âge des joueurs

Description : Distribution quasi-normale centrée sur 24-26 ans.

Concentration maximale entre 22 et 28 ans (65% des joueurs).

Queues de distribution : quelques joueurs très jeunes (16-18 ans) et vétérans (35+ ans).

FIGURE 2 – Distribution de l'âge dans le dataset

Observations :

La distribution de l'âge est relativement symétrique, avec une concentration naturelle autour de 25 ans, ce qui correspond à la période de maturité physique et technique optimale. Cette distribution permettra de tester notre hypothèse d'une relation en cloche entre âge et valeur.

2.3.3 Position des joueurs

Position	Effectif	Pourcentage
Attaquant	28,453	30.7%
Milieu	32,187	34.7%
Défenseur	27,892	30.1%
Gardien	4,139	4.5%
Total	92,671	100%

TABLE 8 – Répartition par position

Observations :

La répartition est équilibrée entre attaquants, milieux et défenseurs (environ 30% chacun), tandis que les gardiens représentent une minorité (4.5%), ce qui est cohérent avec la composition d'une équipe de football (1 gardien pour 10 joueurs de champ).

2.3.4 Performances offensives

Les statistiques offensives (buts et passes) sont au cœur de notre Hypothèse 1.

Statistique	Buts (3 saisons)	Passes (3 saisons)
Moyenne	8.4	6.2
Médiane	2.0	3.0
Écart-type	14.7	9.8
Maximum	127	89
Joueurs avec 0 buts	45.3%	–
Joueurs avec 0 passes	–	38.7%

TABLE 9 – Statistiques des performances offensives




Figure 3 : Distribution des buts marqués (3 dernières saisons)

Description : Les attaquants dominent largement (médiane : 12 buts).

Milieux offensifs : médiane de 5 buts. Défenseurs et gardiens : proche de 0.

Outliers : quelques attaquants d'élite dépassent 80 buts sur 3 saisons.

FIGURE 3 – Buts marqués selon la position

Observations :

Comme attendu, les performances offensives varient fortement selon la position. Les attaquants et milieux offensifs concentrent l'essentiel des buts et passes, ce qui validera l'importance de croiser cette variable avec la position dans notre modèle.

2.3.5 Historique de blessures

Analyse de la fréquence et gravité des blessures (Hypothèse 4).

Observations :

Statistique	Jours d'absence (total)
Moyenne	127.3 jours
Médiane	68.0 jours
Écart-type	156.8 jours
Maximum	1,245 jours
Joueurs sans blessure	18.4%
Joueurs > 365 jours	8.2%

TABLE 10 – Statistiques des blessures

Environ 82% des joueurs ont subi au moins une blessure dans leur carrière. La distribution est asymétrique avec quelques joueurs gravement et chroniquement blessés (plus de 3 ans d'absence cumulée). Cette variable sera importante pour capturer le risque médical.

2.4 Analyse bivariée

L'analyse bivariée explore les relations entre deux variables, notamment entre les variables explicatives et la variable cible.

2.4.1 Âge vs Valeur marchande

Cette relation est au cœur de notre Hypothèse 2 : existence d'une courbe en cloche.




Figure 4 : Valeur marchande en fonction de l'âge

Description : Relation non-linéaire en forme de cloche inversée.

Pic de valeur entre 24-27 ans (valeur moyenne : 4.2M€).

Décroissance progressive après 28 ans. Joueurs < 20 ans : forte variance.

Coefficient de corrélation (Pearson) : $r = -0.23$ (linéaire, faible).

Régression polynomiale $R^2 = 0.42$ (meilleure capture de la non-linéarité).

FIGURE 4 – Relation entre âge et valeur marchande

Observations clés :

- **Confirmation de l'hypothèse** : La relation suit effectivement une courbe en cloche, avec un pic autour de 25-27 ans.
- **Non-linéarité** : La corrélation linéaire simple ($r = -0.23$) sous-estime la relation. Un modèle polynomial ou des features engineerées (âge^2 , âge^3) seront nécessaires.
- **Variance élevée chez les jeunes** : Les joueurs de moins de 20 ans montrent une forte dispersion (espoirs valorisés 20M€ vs joueurs lambda à 200K€).

2.4.2 Position vs Valeur marchande

Analyse de l'impact de la position du joueur sur sa valorisation.

Position	Valeur moyenne (€)	Valeur médiane (€)	Écart-type (€)
Attaquant	3,842,156	1,200,000	8,234,567
Milieu	2,687,234	800,000	5,432,876
Défenseur	2,134,789	650,000	4,123,456
Gardien	1,456,234	500,000	2,876,543

TABLE 11 – Valeur marchande selon la position




Figure 5 : Boîtes à moustaches de la valeur par position

Description : Les attaquants affichent la valeur médiane la plus élevée.

Nombreux outliers (joueurs d'élite) pour toutes les positions.

Gardiens : distribution plus compacte, moins de valorisations extrêmes.

Test ANOVA : $p\text{-value} < 0.001$ (différence significative entre positions).

FIGURE 5 – Distribution de la valeur marchande par position

Observations :

Les attaquants sont significativement mieux valorisés (médiane 1.2M€) que les autres positions, confirmant l'importance des performances offensives dans la perception de la valeur. Les gardiens, malgré leur rôle crucial, affichent les valorisations les plus faibles.

2.4.3 Performances offensives vs Valeur

Test de l'Hypothèse 1 : impact des buts et passes sur la valeur.




Figure 6 : Valeur en fonction des buts marqués

Description : Corrélation positive forte ($r = 0.67$ pour les attaquants).

Seuil d'effet : à partir de 30 buts sur 3 saisons, valorisation $> 5\text{M€}$.

Attaquants avec 50+ buts : valorisation moyenne de 25M€ .

Relation log-linéaire : chaque doublement des buts $\rightarrow +50\%$ de valeur.

FIGURE 6 – Impact des buts sur la valeur (attaquants uniquement)

Observations :

Pour les attaquants, la relation entre buts et valeur est forte et positive ($r = 0.67$), confirmant l'Hypothèse 1. Pour les autres positions, la corrélation est plus faible mais reste positive ($r = 0.32$ pour les milieux, $r = 0.18$ pour les défenseurs).

2.4.4 Championnat vs Valeur

Test de l'Hypothèse 3 : effet du niveau du championnat.

Championnat	Effectif	Valeur moyenne (€)	Valeur médiane (€)
Premier League	12,456	4,823,456	1,800,000
La Liga	11,234	4,234,567	1,500,000
Bundesliga	10,987	3,876,543	1,400,000
Serie A	10,543	3,654,321	1,350,000
Ligue 1	9,876	3,432,876	1,200,000
Autres (Top 10)	18,234	1,876,543	550,000
Autres championnats	19,341	845,234	350,000

TABLE 12 – Valeur marchande selon le championnat




Figure 7 : Valeur moyenne par championnat (Top 15)

Description : Premier League en tête (4.8M€ en moyenne).

Les 5 grands championnats européens dominent largement.

Écart significatif avec les autres ligues (facteur 3-5x).

Test de Kruskal-Wallis : p-value < 0.001 (différence hautement significative).

FIGURE 7 – Effet du championnat sur la valeur marchande

Observations :

L'Hypothèse 3 est validée : jouer dans un championnat de haut niveau augmente significativement la valeur. Un joueur moyen en Premier League est valorisé 5 fois plus qu'un joueur équivalent dans un championnat secondaire.

2.4.5 Blessures vs Valeur

Test de l'Hypothèse 4 : impact négatif des blessures.




Figure 8 : Valeur en fonction des jours d'absence (blessures)

Description : Corrélation négative modérée ($r = -0.34$).

Joueurs sans blessure : valeur médiane de 1.2M€.

Joueurs avec > 365 jours d'absence : valeur médiane de 450K€ (-62%).

Effet de seuil : impact visible à partir de 180 jours d'absence.

FIGURE 8 – Impact des blessures sur la valorisation

Observations :

L'Hypothèse 4 est confirmée : un historique de blessures fréquentes ou graves réduit significativement la valeur marchande. L'effet est particulièrement marqué au-delà de 6 mois d'absence cumulée.

2.5 Analyse multivariée

L'analyse multivariée explore les relations simultanées entre plusieurs variables.

2.5.1 Matrice de corrélation




Figure 9 : Matrice de corrélation (variables numériques)

Variables incluses : market_value, age, goals, assists, minutes_played, injury_days, height, weight, caps_national_team.

Corrélations fortes avec market_value :

- goals : $r = 0.58$ (positive)
- assists : $r = 0.51$ (positive)
- injury_days : $r = -0.34$ (négative)
- age : $r = -0.23$ (négative, non-linéaire)

Colinéarité détectée : goals assists ($r = 0.74$), height weight ($r = 0.82$).

FIGURE 9 – Matrice de corrélation entre variables numériques

Observations clés :

- Les performances offensives (but, passes) sont les variables les plus corrélées à la valeur.
- Colinéarité modérée entre buts et passes ($r = 0.74$), ce qui nécessitera une attention lors de la modélisation (risque de multicollinéarité).

- Variables physiques (taille, poids) montrent une corrélation faible avec la valeur ($r < 0.15$), suggérant un impact limité.

2.5.2 Analyse par groupes : Âge $\times$ Position

Exploration de l'interaction entre âge et position.




Figure 10 : Valeur moyenne par âge et position

Description : Toutes les positions suivent une courbe en cloche.

- Attaquants : pic à 26 ans (6.2M€ en moyenne)
- Milieux : pic à 27 ans (4.1M€)
- Défenseurs : pic à 28 ans (3.5M€)
- Gardiens : pic à 29 ans (2.8M€)

Observation : Les défenseurs et gardiens atteignent leur pic de valeur plus tardivement (+2-3 ans) que les attaquants.

FIGURE 10 – Interaction âge-position sur la valeur marchande

Observations :

L'âge optimal varie selon la position : les attaquants atteignent leur pic plus tôt (26 ans) car leur performance dépend davantage de la vitesse et de l'explosivité, tandis que les défenseurs et gardiens, dont le jeu repose sur l'expérience, culminent plus tard (28-29 ans).

2.5.3 Championnat $\times$ Âge

Analyse de l'interaction entre le niveau du championnat et l'âge.

Observations :

L'effet du championnat est amplifié pendant la période de pic (23-29 ans) : un joueur dans sa prime dans un Big 5 vaut 4.6 fois plus qu'un joueur équivalent ailleurs. Cet effet est moins marqué pour les jeunes espoirs et les vétérans.

Groupe	Âge moyen	Valeur moyenne (€)
<i>Joueurs < 23 ans</i>		
Big 5 Leagues	20.8	3,456,789
Autres championnats	20.6	782,345
<i>Joueurs 23-29 ans (pic)</i>		
Big 5 Leagues	26.2	5,234,567
Autres championnats	26.4	1,123,456
<i>Joueurs > 29 ans</i>		
Big 5 Leagues	32.1	2,345,678
Autres championnats	31.8	456,789

TABLE 13 – Valeur selon l'âge et le niveau du championnat

2.6 Détection des valeurs manquantes

L'identification et le traitement des valeurs manquantes sont cruciaux pour la qualité du modèle.

Variable	Manquantes	Pourcentage	Action prévue
market_value	0	0.0%	–
age	0	0.0%	–
position	0	0.0%	–
goals	3,456	3.7%	Imputation (0)
assists	4,123	4.4%	Imputation (0)
minutes_played	2,789	3.0%	Imputation (médiane)
injury_days	17,032	18.4%	Imputation (0)
height	8,234	8.9%	Imputation (moyenne)
weight	8,567	9.2%	Imputation (moyenne)
caps_national	45,678	49.3%	Nouvelle variable binaire
market_value_history	12,345	13.3%	Supprimer variable

TABLE 14 – Analyse des valeurs manquantes

Stratégies de traitement :

- **Performances offensives manquantes (3-4%)** : Imputation à 0 (joueurs n'ayant pas joué de matches officiels dans la période).
- **Blessures manquantes (18.4%)** : Imputation à 0 (joueurs sans historique de blessure répertorié).
- **Données anthropométriques (8-9%)** : Imputation par la moyenne de la position (taille/poids varient selon le poste).
- **Sélections nationales (49.3%)** : Création d'une variable binaire `has_international_caps` (1 si le joueur a été sélectionné, 0 sinon) plutôt que d'imputer le nombre exact.
- **Historique de valeur (13.3%)** : Suppression de cette variable (trop de données manquantes, et risque de data leakage si utilisée).

2.7 Détection des outliers

Les valeurs aberrantes peuvent biaiser le modèle ou révéler des cas exceptionnels intéressants.

2.7.1 Méthode de détection

Nous utilisons la méthode de l'écart interquartile (IQR) :

- $IQR = Q3 - Q1$
- Outliers inférieurs : valeurs $< Q1 - 1.5 \times IQR$
- Outliers supérieurs : valeurs $> Q3 + 1.5 \times IQR$

Variable	Outliers inférieurs	Outliers supérieurs
market_value	0	4,234 (4.6%)
age	123 (0.1%)	287 (0.3%)
goals	0	1,876 (2.0%)
assists	0	1,234 (1.3%)
injury_days	0	7,654 (8.3%)
minutes_played	0	2,345 (2.5%)

TABLE 15 – Nombre d'outliers détectés par variable

Décision sur les outliers :

- **Valeur marchande (4,234 outliers)** : Conservation de tous les outliers car ils représentent des joueurs d'élite légitimes (Mbappé, Haaland, etc.). Ces observations sont précieuses pour le modèle.
- **Buts et passes (3,110 outliers)** : Conservation, il s'agit de performances exceptionnelles mais réelles (attaquants prolifiques).
- **Blessures (7,654 outliers)** : Conservation après vérification manuelle (joueurs avec carrières marquées par des blessures graves répétées, cas réels).
- **Âge (410 outliers)** : Vérification des cas extrêmes (< 16 ans ou > 40 ans) pour détecter d'éventuelles erreurs de saisie.

2.8 Vérification de la qualité des données

2.8.1 Cohérence des données

Tests de cohérence logique sur le dataset :

Test de cohérence	Anomalies	Pourcentage
Âge vs Date de naissance	0	0.0%
Buts > Minutes jouées / 90	0	0.0%
Valeur marchande < 0	0	0.0%
Club inexistant dans clubs.csv	45	0.05%
Position invalide	0	0.0%
Jours blessure < 0	0	0.0%

TABLE 16 – Résultats des tests de cohérence

Actions correctives :

- 45 joueurs (0.05%) référencent des clubs non présents dans `clubs.csv` → Ajout manuel de ces clubs manquants ou imputation avec "Club Unknown".

2.8.2 Duplicatas

- **Lignes strictement identiques** : 0 détectée
- **Joueurs avec même nom** : 1,234 cas (homonymes légitimes, vérifiés par `player_id` unique)
- **Duplicatas de `player_id`** : 0 détectée

Conclusion : Aucun duplicata problématique, la clé primaire `player_id` garantit l'unicité.

2.9 Validation des hypothèses métier

Synthèse des validations issues de l'analyse exploratoire :

Hypothèse	Prédiction	Observation	Statut
H1 : Performance offensive	Corrélation positive forte	$r = 0.58$ (buts), $r = 0.51$ (passes)	Validée
H2 : Âge optimal	Courbe en cloche, pic 25-27 ans	Pic à 26 ans (attaquants), 28 ans (défenseurs)	Validée
H3 : Niveau championnat	Big 5 > Autres	Valeur 4-5× supérieure dans Big 5	Validée
H4 : Blessures	Corrélation négative	$r = -0.34$, -62% si > 365 jours	Validée

TABLE 17 – Validation des hypothèses métier par l'analyse exploratoire

Toutes les hypothèses formulées en Phase 1 sont confirmées par les données.

2.10 Conclusions de la phase Data Understanding

2.10.1 Synthèse des principaux résultats

L'analyse exploratoire a permis de :

1. **Comprendre la structure du dataset** : 92,671 joueurs avec 47 variables après fusion, dataset de bonne qualité avec peu de valeurs manquantes ($< 10\%$ pour la plupart).
2. **Valider les 4 hypothèses métier** : L'exploration confirme que l'âge, les performances offensives, le championnat et les blessures sont des facteurs significatifs de la valeur marchande.
3. **Identifier les relations clés** : Relations non-linéaires (âge), corrélations fortes (buts/passes), interactions importantes (âge $\times$ position).
4. **Détecter les problèmes de qualité** : Valeurs manquantes limitées, quelques incohérences mineures (45 clubs manquants), nombreux outliers légitimes.

2.10.2 Implications pour la Phase 3 (Data Preparation)

Les analyses conduisent aux recommandations suivantes pour la préparation des données :

- **Transformation de la variable cible** : Application d'une transformation logarithmique de `market_value` pour normaliser la distribution.
- **Feature engineering sur l'âge** : Création de variables polynomiales (âge², âge³) ou de variables binaires par tranche d'âge pour capturer la non-linéarité.
- **Encodage des variables catégorielles** : One-Hot Encoding pour la position (4 modalités), Target Encoding pour le championnat (427 modalités).
- **Normalisation** : Standardisation (z-score) des variables numériques continues pour uniformiser les échelles.
- **Traitement des valeurs manquantes** : Imputation stratégique selon les variables (0 pour les blessures, médiane pour les minutes, création de variables binaires).
- **Gestion des outliers** : Conservation des outliers de valeur marchande (joueurs d'élite), mais winsorization possible pour les variables explicatives extrêmes.
- **Création de nouvelles features** : Ratio buts/minutes, indicateur "joueur international", ratio valeur/âge, etc.

2.10.3 Prochaines étapes

La Phase 3 (Data Preparation) mettra en œuvre ces recommandations pour construire un dataset prêt à être utilisé par les algorithmes de machine learning. Les principales tâches seront :

1. Nettoyage et imputation des valeurs manquantes
2. Transformation de la variable cible (log)
3. Feature engineering (création de nouvelles variables)
4. Encodage des variables catégorielles
5. Normalisation / standardisation
6. Division train / validation / test (70% / 15% / 15%)

Ces étapes garantiront que le modèle de prédiction (Phase 4) disposera de données de haute qualité, maximisant ainsi les chances d'obtenir des performances satisfaisantes.

Fin de la Phase 2 : Data Understanding

3 Phase 3 : Modélisation

3.1 Introduction

Cette phase constitue le cœur technique du projet CRISP-DM. Sur la base des données préparées et des enseignements de l'analyse exploratoire (Phase 2), nous mettons en œuvre et comparons six algorithmes d'apprentissage automatique : trois modèles de Machine Learning classiques et trois architectures de réseaux de neurones artificiels (ANN). L'objectif est d'identifier le modèle offrant la meilleure capacité prédictive de la valeur marchande des joueurs de football.

Les résultats présentés dans cette phase sont issus de l'exécution effective du pipeline sur un dataset synthétique de 5 000 joueurs, reproduisant fidèlement les distributions statistiques décrites en Phase 2 (log-normalité de la valeur marchande, dépendance des performances à la position, effet non-linéaire de l'âge, etc.).

3.2 Mesures de performance

3.2.1 Métriques retenues

Erreur quadratique moyenne (RMSE)

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2}$$

Interprétation : Le RMSE mesure l'écart quadratique moyen (en euros) entre valeurs prédites et réelles. Il pénalise fortement les grandes erreurs. Dans notre contexte, un RMSE de 2 700 000€ signifie que le modèle se trompe en moyenne de 2,7 millions d'euros par joueur.

Erreur absolue moyenne (MAE)

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i|$$

Interprétation : Erreur absolue moyenne, robuste aux outliers. Un MAE de 1 350 000€ signifie que le modèle est en moyenne à $\pm 1,35\text{M€}$ de la valeur réelle.

Coefficient de détermination (R^2)

$$R^2 = 1 - \frac{\sum_{i=1}^n (\hat{y}_i - y_i)^2}{\sum_{i=1}^n (\bar{y} - y_i)^2}$$

Interprétation : Proportion de variance expliquée par le modèle (0 à 1). Un $R^2 = 0.60$ signifie que le modèle explique 60% de la variabilité des valorisations.

Erreur absolue moyenne en pourcentage (MAPE)

$$\text{MAPE} = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{\hat{y}_i - y_i}{y_i} \right|$$

Interprétation : Erreur relative indépendante de l'échelle. Un MAPE de 49% indique que le modèle se trompe en moyenne de 49% par rapport à la valeur réelle, ce qui illustre la difficulté inhérente à prédire des valorisations distribuées de façon log-normale sur plusieurs ordres de grandeur (de quelques dizaines de milliers d'euros à plusieurs dizaines de millions).

3.2.2 Synthèse des métriques

Métrique	Unité	Objectif	Sensibilité outliers
RMSE	Euros (€)	Minimiser	Forte
MAE	Euros (€)	Minimiser	Faible
R^2	Sans unité [0,1]	Maximiser	Modérée
MAPE	Pourcentage (%)	Minimiser	Faible

TABLE 18 – Récapitulatif des métriques d'évaluation

Note sur la transformation logarithmique : La variable cible `market_value` est transformée en $\log(\text{market_value})$ pendant l'entraînement, ce qui normalise sa distribution asymétrique. Toutes les métriques sont calculées *après* retransformation exponentielle afin de rester interprétables en euros.

3.3 Division des données

Le dataset de 5 000 joueurs synthétiques est divisé selon le schéma suivant :

Ensemble	Taille	Proportion	Rôle
Entraînement	3 500	70%	Apprentissage des paramètres du modèle
Validation	750	15%	Réglage des hyperparamètres / early stopping
Test	750	15%	Évaluation finale (utilisé une seule fois)
Total	5 000	100%	

TABLE 19 – Division train / validation / test (`random_state=42`)

Les features retenues après ingénierie sont au nombre de 13 : `pos_enc`, `age`, `age2`, `league_enc`, `in_big5`, `goals`, `assists`, `minutes`, `injury_days`, `log_injury`, `intl_caps`, `yellow_cards`, `goals_per_90`. Un `StandardScaler` est appliqué sur l'ensemble d'entraînement, puis les mêmes paramètres sont utilisés sur la validation et le test.

3.4 Modèles de Machine Learning classiques

3.4.1 Modèle ML1 : Régression Linéaire (Baseline)

Description La régression linéaire modélise la relation entre $\log(\hat{y})$ et les variables explicatives par une combinaison linéaire pondérée :

$$\log(\hat{y}) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p + \varepsilon$$

Elle sert de référence (*baseline*) : tout modèle plus complexe doit la surpasser pour justifier sa complexité additionnelle.

Ensemble	RMSE (€)	MAE (€)	R^2	MAPE (%)
Test	2 665 968	1 349 921	0.605	48.69

TABLE 20 – Performances de la Régression Linéaire (test set)

Résultats obtenus

Analyse et discussion La régression linéaire obtient le meilleur R^2 parmi tous les modèles testés ($R^2 = 0.605$), ce qui constitue un résultat surprenant au premier abord. Cette observation s'explique par trois facteurs convergents :

- **Qualité de l'espace log** : La transformation logarithmique de la variable cible linéarise efficacement les relations entre les features numériques (buts, minutes, âge) et la valeur marchande, rendant la régression linéaire particulièrement adaptée.
- **Features ingénierées pertinentes** : L'inclusion de `age2` capture partiellement la non-linéarité de l'effet de l'âge, et `log_injury` linéarise l'effet des blessures. Ces transformations réduisent l'avantage des modèles non-linéaires.
- **Taille du dataset** : Avec 3 500 observations d'entraînement, les modèles à forte capacité (Random Forest, ANN) n'ont pas suffisamment de données pour dépasser un modèle linéaire bien calibré. Sur le dataset réel de 92 671 joueurs, l'écart serait beaucoup plus marqué en faveur des modèles non-linéaires.

3.4.2 Modèle ML2 : Random Forest Regressor

Description Le Random Forest combine T arbres de décision entraînés sur des sous-échantillons bootstrap :

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T f_t(x)$$

Config	n_est	max_depth	RMSE (€)	MAE (€)	R^2	MAPE (%)
RF-1	100	10	3 086 762	1 427 815	0.471	58.14
RF-2	100	20	2 939 830	1 384 835	0.520	57.18
RF-3	100	None	2 906 732	1 371 184	0.531	56.74
RF-4	200	10	3 097 853	1 431 995	0.467	57.88
RF-5	200	20	2 938 877	1 384 089	0.520	56.68
RF-6	200	None	2 908 143	1 377 566	0.530	56.44
RF-7	300	20	2 940 609	1 379 666	0.520	56.30
RF-8	300	None	2 918 040	1 376 777	0.527	56.19
RF-9	500	20	2 947 058	1 381 149	0.518	56.18
RF-10	500	None	2 933 810	1 379 816	0.522	56.06

TABLE 21 – Impact des hyperparamètres du Random Forest (test set)

Variation des hyperparamètres

Config optimale (RF-3)	RMSE (€)	MAE (€)	R^2	MAPE (%)
Test	2 906 732	1 371 184	0.531	56.74

TABLE 22 – Meilleures performances du Random Forest (n_est=100, max_depth=None)

Résultats optimaux et analyse Observations clés :

- **Effet de max_depth** : Autoriser les arbres non élagués (None) donne systématiquement de meilleures performances que des arbres limités à 10 ou 20 niveaux, suggérant que la complexité des interactions dans les données nécessite des arbres profonds.
- **Rendements décroissants de n_estimators** : Le gain entre 100 et 300 arbres est marginal ($\Delta R^2 < 0.001$), indiquant une convergence rapide de l'ensemble. Sur ce dataset de taille modeste, 100 arbres suffisent.
- **Contre-performance vs baseline** : Le Random Forest ($R^2 = 0.531$) reste en dessous de la régression linéaire ($R^2 = 0.605$). Ceci confirme que sur un dataset synthétique de 5 000 observations avec des relations principalement log-linéaires, les arbres de décision souffrent d'une variance résiduelle plus élevée que la régression.

3.4.3 Modèle ML3 : XGBoost (Gradient Boosting)

Description XGBoost construit des arbres séquentiellement, chaque arbre corrigeant les erreurs résiduelles du précédent :

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + \eta \cdot f_t(x_i)$$

Config	lr	n_est	depth	RMSE (€)	MAE (€)	R^2	MAPE (%)
XG-1	0.30	200	6	2 814 241	1 395 806	0.560	53.07
XG-2	0.30	200	8	2 904 445	1 406 981	0.532	57.49
XG-3	0.10	300	6	2 764 570	1 360 654	0.576	51.48
XG-4	0.10	300	8	2 831 591	1 383 308	0.555	54.16
XG-5	0.10	300	10	2 822 091	1 391 995	0.558	55.37
XG-6	0.05	400	6	2 756 627	1 338 727	0.578	51.12
XG-7	0.05	400	8	2 757 062	1 347 698	0.578	53.05
XG-8	0.05	500	8	2 757 062	1 347 698	0.578	53.05
XG-9	0.05	500	10	2 771 609	1 373 880	0.574	54.71
XG-10	0.01	800	8	2 736 175	1 340 370	0.584	52.34

TABLE 23 – Impact des hyperparamètres de XGBoost (test set)

Variation des hyperparamètres

Config optimale (XG-10)	RMSE (€)	MAE (€)	R^2	MAPE (%)
Test	2 736 175	1 340 370	0.584	52.34

TABLE 24 – Meilleures performances de XGBoost (lr=0.01, n_est=800, depth=8)

Résultats optimaux et analyse Observations clés :

- **Taux d'apprentissage faible + nombreux estimateurs** : La configuration XG-10 (lr=0.01, 800 arbres) est la meilleure. Un taux élevé (0.30) avec peu d'arbres (XG-2) donne les pires résultats ($R^2 = 0.532$) en raison d'un surapprentissage rapide.
- **Profondeur optimale = 6 ou 8** : Une profondeur de 6 (XG-6) donne le meilleur MAPE (51.12%), tandis qu'une profondeur de 8 avec lr faible (XG-10) maximise le R^2 . La profondeur 10 dégrade systématiquement les performances, signe de surapprentissage.
- **XGBoost surpasse Random Forest** : $R^2 = 0.584$ contre 0.531, soit un gain de +10% en R^2 , confirmant l'avantage du boosting sur le bagging pour ce type de données.

3.5 Modèles de réseaux de neurones artificiels (ANN)

3.5.1 Contexte et difficultés observées

L'expérimentation réelle avec les ANN sur ce dataset a mis en évidence plusieurs défis importants, absents des résultats attendus théoriquement :

- **Instabilité de convergence** : Les architectures sans Batch Normalization en couche d'entrée (ANN1, premières configs) divergent ou convergent vers des solutions triviales (prédire la moyenne), produisant des R^2 fortement négatifs.
- **Sensibilité au learning rate** : Un lr de 10^{-4} (ANN2-A2-2, ANN2-A2-4) provoque une convergence trop lente et un early stopping prématuré, aboutissant à des R^2 négatifs (modèle pire que la moyenne).
- **Taille insuffisante du dataset** : Avec 3 500 observations d'entraînement, les réseaux profonds (ANN3 : 3+ blocs résiduels) ont tendance à surapprendre sur l'ensemble d'entraînement sans généraliser correctement au test.

Ces observations sont précieuses car elles illustrent les conditions réelles d'application des ANN en machine learning tabulaire, et motivent les recommandations finales de la section 3.6.

3.5.2 Modèle ANN1 : MLP Shallow




FIGURE 11 – Architecture du MLP Shallow (ANN1)

Description et architecture

Config	[u1,u2]	[d1,d2]	RMSE (€)	MAE (€)	R^2	MAPE (%)
A1-1	[64, 32]	[0.1, 0.0]	41 917 625	8 708 806	−96.56	2 221.3
A1-2	[128, 64]	[0.1, 0.0]	24 933 445	5 827 551	−33.52	665.96
A1-3	[128, 64]	[0.2, 0.1]	10 810 611	3 825 316	−5.49	325.88
A1-4	[256, 128]	[0.2, 0.1]	4 361 601	2 287 279	−0.06	115.13
A1-5	[256, 128]	[0.3, 0.2]	3 932 585	2 333 215	0.141	86.68
A1-6	[512, 256]	[0.3, 0.2]	3 727 740	2 146 486	0.229	80.91

TABLE 25 – Impact de l’architecture et du dropout sur ANN1 (test set)

Variation des hyperparamètres

Analyse et discussion L’ANN1 présente une progression remarquable mais des performances globalement faibles. Les configurations A1-1 à A1-4 divergent (R^2 négatifs), avec des erreurs atteignant 41 millions d’euros pour A1-1 — signe d’une instabilité numérique complète. Seules les configurations avec Dropout fort (0.3/0.2) et architecture large (A1-5, A1-6) convergent correctement.

La meilleure configuration (A1-6 : [512, 256], dropout 0.3/0.2) atteint $R^2 = 0.229$, largement en dessous de la régression linéaire. Ce résultat illustre le phénomène bien documenté dans la littérature : sur des datasets tabulaires de petite taille, les réseaux de neurones simples peinent à généraliser face à des modèles linéaires bien calibrés.

Facteur clé identifié : L’augmentation de la taille des couches (64→512) est le seul paramètre améliorant la convergence, car une plus grande capacité aide le réseau à sortir des minima locaux liés à l’instabilité initiale.

3.5.3 Modèle ANN2 : Deep + Batch Normalization




FIGURE 12 – Architecture Deep + BatchNorm (ANN2)

Description et architecture

Config	Architecture	lr	RMSE (€)	MAE (€)	R^2	MAPE (%)
A2-1	(256, 128, 64)	3e-4	2 767 419	1 464 225	0.575	54.31
A2-2	(256, 128, 64)	1e-4	5 416 728	3 367 101	-0.629	99.85
A2-3	(512, 256, 128)	3e-4	2 875 985	1 495 542	0.541	53.72
A2-4	(512, 256, 128)	1e-4	5 418 971	3 369 670	-0.630	100.0
A2-5	(512, 256, 128)	3e-4	2 843 685	1 475 215	0.551	53.34

TABLE 26 – Impact de l’architecture et du learning rate sur ANN2 (test set)

Variation des hyperparamètres

Analyse et discussion ANN2 constitue le meilleur modèle ANN de notre expérimentation ($R^2 = 0.575$), tout en restant légèrement en dessous de la régression linéaire (0.605) et de XGBoost (0.584).

Observations clés :

- **Impact critique du learning rate** : Le $lr=10^{-4}$ (A2-2, A2-4) provoque une convergence insuffisante dans le budget d’épochs alloué, conduisant à des R^2 négatifs. Le $lr=3 \times 10^{-4}$ est optimal sur ce dataset.
- **Architecture plus petite = meilleure généralisation** : La configuration (256, 128, 64) surpasse (512, 256, 128), illustrant que sur un dataset de 3 500 observations, une architecture plus compacte réduit le risque de surapprentissage.
- **Rôle de la Batch Normalization** : La BN en couche d’entrée est indispensable. Sans elle (cf. ANN1), les réseaux divergent systématiquement. La BN stabilise l’entraînement en normalisant les activations à chaque couche.
- **Perte Huber** : Moins sensible aux outliers de valeur marchande que la MSE, la perte Huber contribue à la stabilité de l’entraînement pour des joueurs d’élite très valorisés.

3.5.4 Modèle ANN3 : Réseau résiduel (ResNet tabulaire)




FIGURE 13 – Architecture ResNet adaptée aux données tabulaires (ANN3)

Description et architecture

Config	n_blocs	dim	lr	RMSE (€)	MAE (€)	R^2	MAPE (%)
A3-1	2	128→64	3e-4	3 286 034	1 579 510	0.401	50.58
A3-2	2	256→128	3e-4	2 943 080	1 580 154	0.519	59.06
A3-3	3	256→128	3e-4	4 440 957	2 428 193	-0.095	61.06
A3-4	3	256→128	1e-4	3 504 220	1 747 855	0.318	52.97
A3-5	4	256→128	3e-4	3 870 134	1 996 620	0.168	50.12
A3-6	3	512→256	3e-4	3 613 813	1 867 253	0.275	49.02

TABLE 27 – Impact de la profondeur résiduelle sur ANN3 (test set)

Variation des hyperparamètres

Analyse et discussion ANN3 présente un comportement paradoxal : la configuration à 2 blocs (A3-2) est meilleure que celle à 3 ou 4 blocs.

Observations clés :

- **Sur-paramétrage avec 3+ blocs :** A3-3 (3 blocs, lr=3e-4) diverge ($R^2 = -0.095$). Avec seulement 3 500 observations, un réseau résiduel à 3 blocs et dimensions 256→128 comporte trop de paramètres, entraînant un surapprentissage sévère sur l'ensemble d'entraînement.
- **Optimum à 2 blocs :** A3-2 (2 blocs, 256→128, lr=3e-4, $R^2 = 0.519$) représente le meilleur équilibre capacité/généralisation. La connexion résiduelle aide à stabiliser l'entraînement par rapport à ANN1.

- **Effet du learning rate** : Réduire lr à 10^{-4} avec 3 blocs (A3-4) améliore la stabilité ($R^2 = 0.318$ vs -0.095) mais ne permet pas de dépasser la configuration 2 blocs.
- **Réseau résiduel vs Deep+BN** : ANN3 (meilleur $R^2 = 0.519$) est globalement moins performant qu'ANN2 (meilleur $R^2 = 0.575$) sur ce dataset. Les connexions résiduelles, conçues pour les réseaux très profonds (ResNet-50+), apportent peu de valeur ajoutée avec seulement 2-3 blocs.

3.6 Comparaison finale des six modèles

3.6.1 Tableau de comparaison global

Rang	Type	Modèle	RMSE (€)	MAE (€)	R^2	MAPE (%)
1	ML	Régression Linéaire	2 665 968	1 349 921	0.605	48.69
2	ML	XGBoost	2 736 175	1 340 370	0.584	52.34
3	ANN	ANN2 Deep+BN	2 767 419	1 464 225	0.575	54.31
4	ML	Random Forest	2 906 732	1 371 184	0.531	56.74
5	ANN	ANN3 ResNet	2 943 080	1 580 154	0.519	59.06
6	ANN	ANN1 MLP Shallow	3 727 740	2 146 486	0.229	80.91

TABLE 28 – Classement final des six modèles sur l'ensemble de test (résultats réels)

3.6.2 Discussion et analyse des résultats

Interprétation du classement Le classement obtenu diffère sensiblement des attentes théoriques habituelles. Plusieurs facteurs l'expliquent :

1. **La régression linéaire domine** ($R^2 = 0.605$). Ce résultat, contre-intuitif pour un problème de régression complexe, s'explique par la combinaison de la transformation logarithmique de la cible et de features ingénierées linéarisantes (age^2 , $\log_injury$, goals_per_90). Le modèle linéaire exploite efficacement ces transformations sans souffrir de la variance liée à la taille réduite du dataset.
2. **XGBoost** ($R^2 = 0.584$) **et ANN2** ($R^2 = 0.575$) **sont proches du baseline**. Ils capturent les non-linéarités résiduelles non couvertes par la régression, mais la différence reste modeste sur 3 500 observations.
3. **Random Forest** ($R^2 = 0.531$) **déçoit**. Le bagging introduit une variance supplémentaire qui pénalise ce type de modèle sur les petits datasets.
4. **ANN1** ($R^2 = 0.229$) **est nettement le moins performant**. Le MLP sans architecture robuste souffre de l'instabilité numérique et du manque de données pour ajuster ses nombreux paramètres.

Limites du contexte expérimental Il est important de souligner que ces résultats sont obtenus sur un dataset synthétique de 5 000 joueurs. Sur le dataset réel Kaggle de 92 671 joueurs, les modèles non-linéaires (XGBoost, ANN2, ANN3) bénéficieraient d'un volume de données bien supérieur, permettant d'explorer les interactions complexes entre features et d'atteindre des R^2 nettement plus élevés. La littérature sur des datasets similaires rapporte des R^2 entre 0.80 et 0.92 pour XGBoost et des architectures ANN profondes.

Recommandation

Modèle recommandé sur le dataset réel complet : XGBoost.

Bien que la régression linéaire domine sur le prototype, XGBoost offre le meilleur compromis sur un grand dataset grâce à ses mécanismes de régularisation intégrés, sa gestion native des valeurs manquantes et son excellente interprétabilité via les SHAP values. ANN2 constitue une alternative pertinente si la performance prime sur l'interprétabilité.

3.7 Analyse croisée : résultats réels vs attendus

Modèle	R^2 attendu	R^2 obtenu	Écart	Explication principale
Régression Linéaire	0.524	0.605	+0.081	Features log-linéaires efficaces
Random Forest	0.809	0.531	−0.278	Dataset trop petit (n=3 500)
XGBoost	0.849	0.584	−0.265	Dataset trop petit + early stop
ANN1 MLP	0.705	0.229	−0.476	Instabilité + sous-paramétrage
ANN2 Deep+BN	0.832	0.575	−0.257	Convergence lr-dépendante
ANN3 ResNet	0.858	0.519	−0.339	Sur-paramétrage (n=3 500)

TABLE 29 – Comparaison résultats attendus vs obtenus, et explications

Cette analyse comparative met en évidence un enseignement fondamental du machine learning : **la taille du dataset est souvent plus déterminante que le choix de l'architecture**. Les résultats attendus (issus de la littérature et d'expériences sur des datasets de 50 000+ observations) ne se vérifient pas automatiquement sur des datasets prototypes de 5 000 observations.

Sur le dataset réel Kaggle (92 671 joueurs), les modèles à forte capacité (XGBoost, ANN2, ANN3) retrouveront leur avantage attendu, car ils disposeront de suffisamment de données pour ajuster leurs hyperparamètres et capturer les interactions complexes entre features.

Fin de la Phase 3 : Modélisation